

《深度学习课程》

课程报告

报告题目 深度学习模型发展历程与最新架构调研报告

学院系别 未提供

专业名称 未提供

学生姓名 未提供

学生学号 未提供

任课教师 未提供

2026 年 6 月 12 日

目 录

第一章 绪论：为什么从“发展历程”理解最新架构.....	2
第二章 深度学习模型的发展历程.....	2
2.1 从浅层可学习模型到反向传播.....	2
2.2 CNN：把空间归纳偏置写进网络	3
2.3 大数据、GPU 与深层视觉网络.....	3
2.4 Transformer 与预训练范式.....	4
第三章 目前最新的深度学习模型架构.....	4
3.1 Dense Transformer 仍是主干，但不再是唯一答案	4
3.2 MoE：用稀疏激活换取更大容量.....	5
3.3 SSM/Mamba：重新思考长序列效率	5
3.4 多模态基础模型：从“模型”走向“系统”.....	5
第四章 个人思考：深度学习未来的几个方向.....	7
4.1 未来不是单一架构胜利，而是混合化.....	7
4.2 数据、算力和对齐将重新塑造架构.....	7
4.3 对课程学习的启发.....	7
第五章 结论.....	8
参考文献.....	9

第一章 绪论：为什么从“发展历程”理解最新架构

深度学习不是一条单纯“模型越来越大”的直线，而是一组围绕表示、优化、数据、算力和任务形态反复重组的技术路线。早期神经网络试图用形式化神经元描述逻辑计算，McCulloch 和 Pitts 的工作把神经活动与命题逻辑联系起来，为后来的人工神经元模型提供了抽象起点^[1]；Rosenblatt 的感知机进一步把学习规则引入分类模型，但其能力也受限于线性可分问题和浅层表示^[2]。从今天回看，这些早期模型的重要性不在于性能，而在于提出了一个持久问题：机器能否通过可学习参数自动形成有效表示。

本报告围绕两个问题展开。第一，深度学习模型的架构为什么会从感知机、CNN、RNN/LSTM 发展到 Transformer 与基础模型。第二，截至 2026 年 6 月 12 日，最新架构的主流方向是什么，它们分别试图解决什么瓶颈。我个人的理解是：深度学习的发展主线并不是“找到一个万能结构”，而是在不同约束下寻找更好的归纳偏置、训练稳定性、上下文建模能力和计算效率之间的平衡。

报告问题	关注点	主要证据
发展历程	架构变化对应的技术瓶颈	经典论文、模型结构、训练方式
最新架构	2024-2026 年主流前沿方向	MoE、SSM/Mamba、多模态基础模型、AI Index
个人思考	未来方向与限制	效率、可靠性、可解释性、系统化智能

第二章 深度学习模型的发展历程

2.1 从浅层可学习模型到反向传播

感知机时代的核心贡献是把“规则设计”转向“参数学习”。但是浅层模型通常难以学习复杂层级特征，真正让多层网络可训练的是反向传播的普及。Rumelhart、Hinton 和 Williams 在 1986 年系统展示了通过误差反向传播调整多层网络权重的方法，使隐藏层能够形成任务相关的内部表示^[3]。从架构角度看，这一阶段解决的是“深层模型能否训练”的问题，而不是“模型应该长成什么形状”的问题。

我的理解是，反向传播的意义常被简化成一个算法技巧，但它实际上改变了建模分工：过去人类负责特征工程，模型只做较浅的判别；反向传播以后，特征抽取本身成为优化目标的一部分。也正因为如此，后来的 CNN、RNN 和 Transformer 都可以看作是在“可微端到端训练”框架下，为不同数据形态设计更合适的结构约束。

2.2 CNN：把空间归纳偏置写进网络

卷积神经网络的代表性意义在于把局部连接、权值共享和平移等变性写入架构。LeCun 等人在手写字识别中展示了梯度学习与卷积结构结合的有效性^[4]。CNN 的成功不是因为它比全连接网络更“大”，而是因为它更懂图像：局部纹理可以组合成边缘、部件和目标，卷积核在不同位置共享参数，既降低了参数量，也增强了泛化。

RNN 和 LSTM 则试图处理序列中的时间依赖。标准 RNN 容易遇到梯度消失和长期依赖问题，LSTM 通过门控记忆机制缓解了这一瓶颈^[5]。因此，CNN 和 LSTM 代表了深度学习早期成熟阶段的两类典型思路：一种面向空间结构，一种面向时间结构。它们说明“模型架构”本身就是一种假设：图像、文本、语音、时间序列并不应当被完全相同地处理。

2.3 大数据、GPU 与深层视觉网络

2012 年 AlexNet 在 ImageNet 上的表现标志着深度学习进入大规模视觉识别阶段，其成功结合了大数据集、GPU 训练、ReLU、Dropout 和深层 CNN 等因素^[6]。此后，网络加深带来了优化困难，ResNet 用残差连接将深层网络学习目标改写为残差函数，显著缓解了退化问题^[7]。从这条线索看，深度学习的进步常常不是单点突破，而是数据规模、硬件、训练技巧和结构设计共同达到临界点。

在我看来，ResNet 的价值不仅是“更深”，而是提出了一种工程上极其重要的思想：当直接学习目标函数困难时，可以改变网络内部的信息路径，让优化问题变得更平滑。这种思想后来在 Transformer 的残差连接、归一化、跳连结构以及现代扩散模型中都能看到影子。




图 2.1 深度学习模型架构演化概念图

图中将深度学习模型演化概括为八个阶段。它不是严格的历史年表，而是强调每个阶段解决

的主要问题：从可学习分类器，到可训练深层网络，再到空间层级、序列记忆、并行注意力、基础模型、稀疏路由和长上下文效率。

2.4 Transformer 与预训练范式

Transformer 的突破在于用自注意力取代循环结构，使序列建模可以更充分地并行化，并让模型直接学习任意 token 之间的依赖关系^[8]。BERT 展示了大规模无监督预训练加下游微调的有效性，强调双向上下文表示^[9]；GPT-3 则进一步展示了规模化语言模型在少样本提示下的泛化能力^[10]。这一阶段的变化非常关键：模型不再只是为某个单一任务从零训练，而是先在大规模数据上形成通用表示，再通过提示、微调或对齐服务不同任务。

Transformer 也跨出了语言领域。Vision Transformer 将图像切成 patch，并把视觉问题转换成 token 序列建模问题^[11]。扩散模型则在生成任务中形成另一条主线，DDPM 通过逐步去噪实现高质量生成^[12]，DiT 又把 Transformer 引入扩散模型主干，进一步说明 token 化和注意力结构正在成为多模态建模的通用接口^[13]。

阶段	主要结构	解决的瓶颈	新问题
感知机/浅层网络	线性分类器、简单神经元	从规则到学习	表示能力弱
CNN/ResNet	卷积、残差连接	空间层级与深层优化	跨模态统一性不足
RNN/LSTM	循环与门控记忆	序列依赖	并行效率低
Transformer	自注意力、残差、归一化	全局上下文与并行训练	长上下文计算代价高
基础模型	大规模预训练、提示学习	跨任务泛化	成本、对齐与可靠性

第三章 目前最新的深度学习模型架构

3.1 Dense Transformer 仍是主干，但不再是唯一答案

截至 2026 年，Transformer 仍然是语言模型、多模态模型和扩散生成模型的核心主干之一。原因很直接：它的自注意力机制通用、并行友好，工程生态成熟，并能与大规模预训练很好结合。但是它的代价也很明显：注意力计算随序列长度增长而变重，大模型全参数激活导致推理成本高，多模态输入和工具调用又进一步放大上下文长度压力。

因此，所谓“最新架构”更准确地说是后 Transformer 时代的架构族群：Dense Transformer 作为基线仍在演进；MoE 用条件计算提高参数容量与成本比；SSM/Mamba 试图用线性时间序列建模改善长上下文效率；多模态基础模型则把视觉、文本、视频、语音和工具使用统一到更复杂的系统中。

3.2 MoE：用稀疏激活换取更大容量

Mixture of Experts 的核心想法是让每个 token 只激活部分专家网络，从而在总参数规模很大时控制单次计算成本。Switch Transformer 展示了用简单稀疏路由扩展到超大参数规模的可行性^[14]。与稀疏专家路线并行，Mamba 和 Mamba-2 又从状态空间模型角度重新讨论长序列效率^[15-16]。到 DeepSeek-V3 这类技术报告中，MoE 已经成为前沿大语言模型的重要路线之一，其目标不是简单堆参数，而是提高“模型容量/实际计算量”的比值^[17]。

但 MoE 也带来新的工程问题：路由负载均衡、专家利用率、通信开销、训练稳定性和推理部署复杂度。我的判断是，MoE 更像一种“系统架构”而不是单纯“网络层结构”：它把模型质量问题部分转化为调度、通信和并行计算问题。未来能否继续扩展，取决于硬件互联、编译器、推理框架和训练算法能否一起进步。

3.3 SSM/Mamba：重新思考长序列效率

状态空间模型路线关注的是长序列建模效率。Mamba 将选择性状态空间模型整合成端到端序列主干，强调线性时间扩展和硬件友好实现^[15]。Mamba-2 进一步从结构化状态空间对偶角度建立 SSM 与注意力之间的联系，并报告更高效的算法设计^[16]。这条路线的重要性在于，它没有把 Transformer 视为不可替代的终点，而是追问：长上下文建模到底需要完整二次注意力，还是可以用选择性状态传播实现更高性价比。

我认为 SSM/Mamba 的未来价值不一定是完全取代 Transformer，而可能是形成混合架构。例如局部高频信息用状态扫描处理，关键跨段关系仍用注意力或检索机制补充。对于长视频、长文档、基因序列、日志序列和持续交互式智能体，这类结构的吸引力会越来越强。

3.4 多模态基础模型：从“模型”走向“系统”

最新深度学习架构的另一条主线是多模态基础模型。Qwen3 报告展示了 dense 与 MoE 等不同模型形态下的能力扩展^[18]；Qwen3-VL 则将文本、图像和视频统一到视觉语言模型中，并支持长上下文、多图像和视频理解等能力^[19]。这说明前沿模型正在从“单一输入、单一输出”的网络，转向“多模态编码、跨模态对齐、长上下文记忆、工具调用和安全对齐”的系统。

2026 年 AI Index 也显示，前沿 AI 能力仍在加速，产业界贡献了大多数 notable frontier models，模型在多模态推理、科学问题和代码任务上持续提升，但负责任 AI 测量、基础设施能耗和治理能力仍然落后于能力增长^[20]。这提醒我们：最新架构不是只看 benchmark 分数，还要看成本、透明度、可靠性和社会部署条件。




图 3.1 后 Transformer 时代主要架构方向概念图

这张图把后 Transformer 时代的架构方向概括为四条并行路线：Dense Transformer 保持通用性，MoE 追求稀疏激活，SSM/Mamba 追求长序列效率，多模态基础模型追求跨模态统一。图中的检索、工具与安全对齐提醒我们，现代深度学习已经越来越像一个端到端系统，而不是孤立的神经网络层堆叠。

Architecture Trade-off Map: From Dense Perception to Selective Foundation Models




图 3.2 架构取舍图：从稠密感知到选择性基础模型

架构方向	代表机制	优势	风险或限制
Dense Transformer	全参数注意力与前馈网络	生态成熟、效果稳定、可迁移性强	长上下文和推理成本高
MoE	路由器选择专家	参数容量大、单次激活成本可控	路由、通信和部署复杂
SSM/Mamba	选择性状态传播	长序列线性扩展潜力	大规模通用能力仍需持续验证

多模态基础模型	视觉/文本/视频对齐	更接近真实任务输入	数据治理、幻觉、安全和评测更难
Agentic Model	记忆、工具、规划、反馈	可执行复杂 workflows	错误累积、权限和可控性问题

第四章 个人思考：深度学习未来的几个方向

4.1 未来不是单一架构胜利，而是混合化

我不认为未来几年会出现一个完全取代 Transformer 的单一结构。更可能的趋势是混合化：Transformer 继续承担通用 token 交互，MoE 承担容量扩展，SSM/Mamba 承担长序列效率，多模态编码器承担感知输入，检索与工具模块承担外部知识和执行能力。模型架构会越来越像操作系统中的多个子系统：注意力负责全局交互，状态模型负责连续流，专家网络负责专业化，检索工具负责外部世界连接。

这种混合化也意味着评价方式要变化。过去我们容易用单一 benchmark 判断模型优劣，但未来模型的价值更取决于在成本、延迟、可控性、长任务稳定性和安全边界之间的综合表现。一个在静态问答上很强的模型，不一定适合长时间自动执行任务；一个成本很低的长上下文模型，也不一定具备复杂推理可靠性。

4.2 数据、算力和对齐将重新塑造架构

深度学习早期强调网络结构，后来强调数据和算力，今天则进入三者互相制约的阶段。高质量数据越来越稀缺，推理成本成为真实产品部署的关键，安全对齐又要求模型在能力之外具有边界感。架构创新如果不能降低训练或推理成本，很难只靠论文指标长期成立；反过来，如果一种结构能显著降低长上下文或多模态推理成本，即使短期 benchmark 略弱，也可能在应用中获得空间。

我尤其关注两个问题。第一，模型是否能把“会回答”推进到“能稳定完成任务”。这需要长期记忆、工具调用、计划修正和环境反馈，而不只是更长的上下文窗口。第二，模型是否能在不牺牲透明度的情况下提高能力。MoE、检索增强和多模态系统都增加了内部路径复杂度，如果缺少可解释和可追踪机制，部署风险会随能力一起增长。

4.3 对课程学习的启发

从课程学习角度看，理解深度学习架构不能只背模型名称，而应抓住“数据形态、计算路径、优化难度、泛化方式”四个维度。CNN 为什么适合图像，LSTM 为什么引入门控，Transformer 为什么能统一序列建模，MoE 为什么能扩大容量，Mamba 为什么关注线性时间，这些问题比“某

模型参数是多少”更重要。

学习维度	应该追问的问题	对应架构例子
数据形态	输入是否有空间、时间、模态结构	CNN、LSTM、ViT、多模态模型
计算路径	信息如何在层、token、专家之间流动	Transformer、MoE、SSM
优化难度	深层训练是否稳定，梯度是否可传播	反向传播、ResNet、归一化
泛化方式	是任务内学习，还是预训练迁移	BERT、GPT、基础模型
部署约束	成本、延迟、可靠性如何权衡	MoE、Mamba、检索增强

第五章 结论

深度学习模型的发展可以概括为一条持续扩展的主线：从可学习分类器，到端到端表示学习；从图像和序列的专用结构，到 Transformer 的统一 token 建模；再到基础模型、MoE、SSM/Mamba 和多模态系统。每一次架构变化都不是凭空出现，而是在解决上一阶段的瓶颈：表示能力不足、深层优化困难、并行效率低、长上下文代价高、参数容量和推理成本矛盾、多模态任务复杂等。

我对未来的判断是：深度学习会继续沿着“更通用”和“更高效”两条线同时前进。更通用意味着多模态、长上下文、工具使用和持续交互；更高效意味着稀疏激活、线性时间序列建模、模型压缩、专用硬件和更强工程系统。真正值得关注的不是某个模型名字，而是它在能力、成本、可靠性和可治理性之间给出了怎样的取舍。深度学习的下一阶段，很可能不是单个网络结构的胜利，而是模型、数据、工具、硬件和人类反馈共同组成的智能系统的成熟。

参考文献

- [1] McCulloch W S, Pitts W. A logical calculus of the ideas immanent in nervous activity[J]. The Bulletin of Mathematical Biophysics, 1943, 5: 115-133. DOI: 10.1007/BF02478259.
- [2] Rosenblatt F. The perceptron: A probabilistic model for information storage and organization in the brain[J]. Psychological Review, 1958, 65(6): 386-408. DOI: 10.1037/h0042519.
- [3] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. Nature, 1986, 323: 533-536. DOI: 10.1038/323533a0.
- [4] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324. DOI: 10.1109/5.726791.
- [5] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780. DOI: 10.1162/neco.1997.9.8.1735.
- [6] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]//Advances in Neural Information Processing Systems 25. 2012. URL: https://proceedings.neurips.cc/paper_files/paper/2012/hash/c399862d3b9d6b76c8436e924a68c45b-Abstract.html.
- [7] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[R/OL]. arXiv:1512.03385, 2015[2026-06-12]. DOI: 10.48550/arXiv.1512.03385.
- [8] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[R/OL]. arXiv:1706.03762, 2017[2026-06-12]. DOI: 10.48550/arXiv.1706.03762.
- [9] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[R/OL]. arXiv:1810.04805, 2018[2026-06-12]. DOI: 10.48550/arXiv.1810.04805.
- [10] Brown T B, Mann B, Ryder N, et al. Language models are few-shot learners[R/OL]. arXiv:2005.14165, 2020[2026-06-12]. DOI: 10.48550/arXiv.2005.14165.
- [11] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[R/OL]. arXiv:2010.11929, 2020[2026-06-12]. DOI: 10.48550/arXiv.2010.11929.
- [12] Ho J, Jain A, Abbeel P. Denoising diffusion probabilistic models[R/OL]. arXiv:2006.11239, 2020[2026-06-12]. DOI: 10.48550/arXiv.2006.11239.
- [13] Peebles W, Xie S. Scalable diffusion models with transformers[R/OL]. arXiv:2212.09748, 2022[2026-06-12]. DOI: 10.48550/arXiv.2212.09748.
- [14] Fedus W, Zoph B, Shazeer N. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity[R/OL]. arXiv:2101.03961, 2021[2026-06-12]. DOI: 10.48550/arXiv.2101.03961.
- [15] Gu A, Dao T. Mamba: Linear-time sequence modeling with selective state spaces[R/OL]. arXiv:2312.00752, 2023[2026-06-12]. DOI: 10.48550/arXiv.2312.00752.
- [16] Dao T, Gu A. Transformers are SSMs: Generalized models and efficient algorithms through structured state space duality[R/OL]. arXiv:2405.21060, 2024[2026-06-12]. DOI: 10.48550/arXiv.2405.21060.
- [17] DeepSeek-AI, Liu A, Feng B, et al. DeepSeek-V3 technical report[R/OL]. arXiv:2412.19437, 2024[2026-06-12]. DOI: 10.48550/arXiv.2412.19437.

- [18] Qwen Team. Qwen3 technical report[R/OL]. arXiv:2505.09388, 2025[2026-06-12]. DOI: 10.48550/arXiv.2505.09388.
- [19] Bai S, Cai Y, Chen R, et al. Qwen3-VL technical report[R/OL]. arXiv:2511.21631, 2025[2026-06-12]. DOI: 10.48550/arXiv.2511.21631.
- [20] Stanford Institute for Human-Centered Artificial Intelligence. The 2026 AI Index Report[EB/OL]. 2026[2026-06-12]. <https://hai.stanford.edu/ai-index/2026-ai-index-report>.